

Обзор мировых ИИ: фронтир сжался, выбор усложнился

Четыре американские лаборатории и китайский open-weight кластер живут в одной полосе качества. Выигрывает не логотип, а стек: задача × цена × инструменты × юрисдикция данных.

\$582 млрд


корпоративные инвестиции в ИИ за 2025 · +130%

2,7%

разрыв США–Китай по Arena Elo · март 2026

88% / ед.%

организации «используют ИИ» vs агенты в проде



Деньги удвоились. Агенты ещё редкость

Итоги 2025 года: generative AI забрал почти половину частных инвестиций. Внедрение чатов массовое, автономных агентов — нет.



Три контура, не одна гонка

Качество моделей почти сравнялось. Разъехались цена, открытость весов, экосистема и правила про данные.

США · закрытый фронтир

OpenAI · Anthropic · Google · xAI

Ядро качества. Дорогие токены, богатые инструменты, облачная привязка. Топ-4 в марте 2026 уложились в 25 пунктов Arena Elo.

- 1М контекст
- Агенты / tools
- Закрытые веса

Китай · цена и веса

DeepSeek · Qwen · Kimi · GLM

Тот же верхний эшелон на независимых индексах. Open-weight, MoE, контекст до 1М, цена часто на порядок ниже. Лидерство с США менялось несколько раз с 2025-го.

- MIT / открытые веса
- Дешёвый inference
- Свой хостинг

Остальные · своя игра

Европа · Meta · Россия

Mistral и Meta не задают потолок лета 2026. Россия играет не в Elo, а в 152-ФЗ, рубли и данные внутри страны: YandexGPT и GigaChat.

- Локальный контур
- Комплаенс
- Гибридный стек

Четыре США-лаборатории — четыре оси

Флагман отвечает на вопрос «какой потолок». Рабочая лошадка — «чем кормить ежедневный трафик».

OPENAI GPT-5.6 Sol → Terra → Luna Единый Responses-контур и широкие tools. Sol силён в коде и агентах: часто меньше токенов и шагов, чем у Claude. Ловушка: после ~272K токенов дорожает весь запрос.	ANTHROPIC Claude Fable 5 потолок качества Номинальный флагман. На практике многие команды берут Opus 5: дешевле, свежее cutoff, проще с retention. Fable — когда свой прогон доказал преимущество.	GOOGLE DEEPMIND Gemini 3.7 Flash мультимодальность Текст, картинки, аудио, видео, PDF. Скорость декодирования в другом классе. Medium по умолчанию, High — точно. Экосистема Workspace / Cloud / Search.	XAI Grok 4.6 агентный индекс Живой поиск, X, сильные агентные бенчмарки. Контекст 500K. Ценовой обрыв на 200K: 199K и 201K — уже разные счета.
---	--	--	--

Open-weight догнал «достаточно хороший» фронтир

За несколько недель вышли Kimi K3, Qwen 3.8 Max и стабильный DeepSeek V4. Для объёма и своего контура это уже не эксперимент.

Модель	Лаборатория	Масштаб	Зачем брать
DeepSeek V4 Pro / Flash	DeepSeek	1,6T / 284B · MIT	Дешёвый reasoning и код, скачиваемые веса, ночные тарифы
Qwen 3.8 Max	Alibaba	2,4T / 95B акт.	Мультимодальность, агенты, облако Alibaba
Kimi K3	Moonshot	2,8T / 104B акт.	Крупные открытые веса, длинный контекст, код
GLM-5.2	Zhipu / Z.ai	~744B · MIT	Enterprise tool-use и агентные сценарии

Цена как оружие

V4 Flash остаётся примерно на порядок дешевле Sol на выходных токенах. Для агентов, которые жгут токены пачками, это меняет юнит-экономику.

Контроль, не ноутбук

Чекпоинт на 800+ ГБ — страховка от API и юрисдикции, а не локальный чат. Нужен свой inference-контур.

Разрыв снова чуть раскрылся

К марту 2026 топ закрытой модели впереди открытой примерно на 3,3%. Для большинства прикладных задач это уже шум.

Пять победителей — на пять разных работ

Таблица вендора показывает, что он оптимизировал. Ваш прогон на своих задачах — единственный честный рейтинг.

сложный код GPT-5.6 Sol · Opus 5 Меньше шагов и выходных токенов в агентных обвязках. Берите флагман, когда цена ошибки высока.	трудный анализ Claude Fable / Opus Потолок знания и аккуратность. Сначала Opus: вдвое дешевле Fable и чаще удобнее по политике данных.	мультимодальность Gemini 3.7 Flash Видео, PDF, скорость, Search/Maps. Medium по умолчанию — High не даёт бесплатных очков агентности.	живой поиск Grok 4.6 Сильный агентный индекс и нативный X. Лучше как фоновый исследователь, чем как «мгновенный чат».	объём и контроль DeepSeek · Qwen Скачиваемые веса, дешёвый поток, своя инфраструктура. Текстовый контур сильнее мультимодального.
--	---	--	--	--

Лестница вместо моногамии

Дешёвая модель разведывает и размножает задачи → средняя делает ежедневную работу → флагман планирует и принимает дорогие решения. Считайте стоимость **задачи**, не токена: reasoning, ретраи, длинный контекст и tools съедают «дешёвый» тариф.

Шесть трендов, которые важнее логотипа

1 Конвергенция качества
Топ в узкой полосе Elo. Конкуренция ушла в надёжность, стоимость задачи, инструменты и домен.

2 Агенты: бенчмарк ≠ прод
OSWorld 12% → 66%, Terminal-Bench ~77%. В компаниях агенты всё ещё в единицах процентов функций.

3 Open weights как страховка
Скачать чекпоинт — контроль поставщика и юрисдикции, не замена облаку из коробки.

4 Неровный фронтир
Золото IMO и провал на аналоговых часах (~50% vs 90% у людей).
Способность не переносится сама.

5 Прозрачность падает
Foundation Model Transparency Index: 58 → 40. Самые сильные модели раскрывают меньше всего.

6 Удар по входным ролям
Занятость разработчиков 22–25 лет в США: почти –20% с 2024-го.
Старшие коллеги пока растут.

Не «кто умнее», а где лежат данные

YandexGPT и GigaChat выигрывают доступ, рубли и 152-ФЗ. Потолок сложного кода и длинных агентов — у зарубежных флагманов.

ЯНДЕКС

YandexGPT 5.x · Алиса

Облако Foundation Models, экосистема поиска и Алисы. YandexGPT 5.1 Pro вендор сравнивает со своим миксом уровня GPT-4.1. Есть открытая Lite. Данные и договор — внутри РФ.

СБЕР

GigaChat · on-prem

Широкий ассистент и API для бизнеса. Длиннее контекст на рабочих тарифах, чем у типичного YandexGPT Pro. Есть варианты для размещения у себя — редкость на локальном рынке.

Когда своё

Персональные данные, типовой русский текст, чат-поддержка, документы, оплата в рублях без VPN.

Когда импорт

Сложный код, многошаговые агенты, контекст в сотни тысяч токенов. Легально — через российского агрегатора.

Когда веса

Чувствительный объём и контроль поставщика: китайский open-weight на своей инфраструктуре.

Пять правил стека на вторую половину 2026

- 1

Не выбирать одного победителя на всё

Лестница моделей дешевле и устойчивее моногамии.
- 2

Считать стоимость задачи

Токен, reasoning, ретраи, длинный контекст и tools — одна экономика.
- 3

Прогонять финалистов на своих промтах

Чужая таблица измеряет чужой бенчмарк, не ваш процесс.
- 4

Отдельно проектировать юрисдикцию

152-ФЗ и персональные данные не решаются «самой умной» моделью.
- 5

Агентов запускать узко

Один стабильный процесс важнее «агента вообще».

Коротко

Мировой ИИ в 2026-м — это уже не гонка одной лаборатории. Это рынок платформ, где качество сошлось, а выигрыш уехал в стоимость, контроль и внедрение.

- США = потолок и tools
- Китай = цена и веса
- РФ = комплаенс + гибрид

Источники: Stanford HAI AI Index 2026; публичные линейки OpenAI, Anthropic, Google, xAI, DeepSeek, Alibaba, Moonshot, Zhipu; контур YandexGPT / GigaChat. Это срез, не инвестиционная рекомендация.